

**IMT2111 - Álgebra Lineal Numérica** - 1er Semestre 2019  
**Profesor:** Manuel Sánchez Uribe

## Tarea 1

Nombre: Maximiliano Rivera  
marivera3@uc.cl  
9 de abril de 2019

### Matlab Code

En esta sección se presentan los códigos implementados para esta tarea.

#### QR por el método de Gram-Schmidt clásico

```
1  % Created by Maximiliano Rivera, based on Numerical Linear Algebra by
2  % L.N. Trefethen.
3
4  function [ Q, R ] = QRbyGSC(A)
5  % This function is for decompose a matrix A in matrices Q and R, where Q
6  % has orthonormal columns and R is upper triangular, such that A = QR. This
7  % is possible using the Gram-Schmidt Classical algorithm
8
9  [m, n] = size(A);
10 Q = zeros(m, n);
11 R = zeros(n, n);
12
13 for j=1:n
14     v = A(:, j);
15     r = Q' * v;
16     v = v - Q * r;
17     rjj = norm(v);
18     v = v / rjj;
19     Q(:, j) = v;
20     R(1:j, j) = [r(1:j-1); rjj];
21
22
23 end
24 return
25
26 end
```

## QR por el método de Gram-Schmidt modificado

```
1  % Created by Maximiliano Rivera, based on Numerical Linear Algebra by
2  % L.N. Trefethen.
3
4  function [ Q, R ] = QRbyGSM(A)
5  % This function does QR decomposition with Gram-Schmidt modify algorithm
6
7  [m, n] = size(A);
8  Q = zeros(m, n);
9  R = zeros(n, n);
10 for i=1:n
11     vi = A(:, i);
12     rii = norm(vi);
13     qi = vi/rii;
14     Q(:, i) = qi;
15     % for j=i+1:n
16     %     vj = A(:, j);
17     %     rij = qi'*vj;
18     %     A(:, j) = vj - rij*qi;
19     % end
20     Vj = A(:, i+1:end);
21     rij = qi'*Vj;
22     A(:, i+1:end) = Vj - qi*rij;
23
24     % We can construct R from the rii and rij previously calculated
25     R(i:n, i) = [ rii; rij' ];
26 end
27 R = R';
28 return
29
30 end
```

## QR por el método de Householder

```
1  % Created by Maximiliano Rivera, based on Numerical Linear Algebra by
2  % L.N. Trefethen.
3
4  function [ Q, R ] = QRbyHouseholder(A)
5
6  [m, n] = size(A);
7  Q = eye(m);
8  for k = 1:n
9
10     x = A(k:m, k);
11     e1 = zeros(length(x), 1);
12     e1(1) = 1;
13     v = sign(x(1))*norm(x)*e1 + x;
14     v = v/norm(v);
15     F = eye(m-k+1, m-k+1) - 2*v*(v');
16
17     A(k:m, k:n) = F*A(k:m, k:n);
18
19     Qk = eye(m, m);
20     Qk(end-(m-k):end, end-(m-k):end) = F;
21     Q = Qk*Q; % forming the matrix Q' = Qk...Q2Q1
22 end
23 Q = Q';
24 R = A;
25 return
26 end
```

## Pregunta 2

Maximiliano Rivera


### Problema 2.1

1. El costo de guardar cada elemento de  $A$  es de  $m \cdot n$
2. El costo de guardar cada término de la SVD, es obtener todos los coeficientes de la sumatoria  $\sum_{i=1}^n \sigma_i u_i v_i^*$ , dando un total de  $(m + n + 1) \cdot n$
3. El costo de guardar un término de la SVD es de  $m + n + 1$ , debido a que, con 1 término tenemos:  $\sum_{i=1}^1 \sigma_i u_i v_i^*$ , con  $u_i$  de largo  $m$ ,  $v_i$  largo  $n$ , y  $\sigma_i$  es un escalar.
4. El costo de guardar  $k$  elementos de la SVD es igual a  $(m + n + 1) \cdot k$ , por ende, el  $k$  para que se almacene la misma cantidad de información es  $k = \frac{m \cdot n}{m + n + 1}$ . Esto significa que, utilizando ese  $k$ , la descomposición SVD presenta la misma información que la matriz previa.
5. El error relativo asociado a la imagen con  $k$ -términos es  $\sum_{i=k+1}^n \sigma_i u_i v_i^*$

### Problema 2.2

a) Se crea una matriz  $C \in \mathbb{C}^{10 \times 10 \times 3}$ , para luego encontrar la escala de grises la imagen, quedando  $C_{gray} \in \mathbb{C}^{10 \times 10}$


```
C = rand(10, 10, 3);  
image(C);
```



```

Cgray = rgb2gray(C);
% Cgray = rand(10, 10);
% imshow(Cgray 'CDataMapping','scaled'); colorbar;
% fig = figure();
% ax = axes(fig);
magnification = 6000;
imshow(Cgray, 'InitialMagnification', magnification);

```




b) Se descompone la matriz  $C_{gray}$  según la SVD.

```

[U,S,V] = svd(Cgray);
% image(U*S*V', 'CDataMapping','scaled'); colorbar;
imshow(U*S*V', 'InitialMagnification', magnification);

```



c) Se estima el  $k$  y luego se calcula el SVD para los primeros  $k$  términos.

```

[m, n] = size(Cgray);
k = round(m*n/(m + n+ 1))


```

$k = 5$

```

Sk = S(1:k, 1:k);
Uk = U(:, 1:k);
Vk = V(:, 1:k);
Cgray2 = Uk*Sk*Vk';
% image(Cgray2, 'CDataMapping','scaled'); colorbar;
imshow(Cgray2, 'InitialMagnification', magnification);

```



En esta última figura podemos notar que al utilizar una cantidad de valores singulares reducidos, la matriz resultante es levemente diferente a la matriz original. Esto se debe a la aproximación previamente calculada.

### Problema 2.3

```

Max = im2double(imread('max.bmp'));
imshow(Max)

```



```

magnification2 = 100;
Igray = rgb2gray(Max);
imshow(Igray, 'InitialMagnification', magnification2);

```



b) Descomposición SVD:

```
% Igray_double = double(Igray);
[UI,SI,VI] = svd(Igray);
% image(U*S*V', 'CDataMapping','scaled'); colorbar;
imshow(UI*SI*VI', []);
```



c)

```
[m, n] = size(Igray);
k = round(m*n/(m + n + 1));
% k=300;
SIk = SI(1:k, 1:k);
UIk = UI(:, 1:k);
VIk = VI(:, 1:k);
Igray2 = UIk*SIk*VIk';
% image(Cgray2, 'CDataMapping','scaled'); colorbar;
imshow(Igray2, []);
```




## Problema 2.4

```

Max1 = Max(:, :, 1);
Max2 = Max(:, :, 2);
Max3 = Max(:, :, 3);
% Igray_double = double(Igray);
[U1,S1,V1] = svd(Max1);
[U2,S2,V2] = svd(Max2);
[U3,S3,V3] = svd(Max3);
% image(U*S*V', 'CDataMapping','scaled'); colorbar;
[m, n] = size(Max1);
k = round(m*n/(m + n+ 1));
S1k = S1(1:k, 1:k);
U1k = U1(:, 1:k);
V1k = V1(:, 1:k);
S2k = S2(1:k, 1:k);
U2k = U2(:, 1:k);
V2k = V2(:, 1:k);
S3k = S3(1:k, 1:k);
U3k = U3(:, 1:k);
V3k = V3(:, 1:k);
NewMax = zeros(m, n, 3);
NewMax(:, :, 1) = U1k*S1k*V1k';
NewMax(:, :, 2) = U2k*S2k*V2k';
NewMax(:, :, 3) = U3k*S3k*V3k';
imshow(NewMax)

```





## Pregunta 3

Maximiliano Rivera

Los códigos utilizados están en la siguiente plataforma:

<https://github.com/Marivera3/Algebra-Lineal-Numerica>

Esto fueron implementados por mi, basado en los apuntes del libro texto guía L.N.Trefetehn.

### Problema 3.1

La matriz a considerar es la siguiente

```
A = [1 2 3; 4 5 6; 7 8 7; 4 2 3; 4 2 2];  
cond(A)
```

```
ans = 12.4508
```

```
[Q, R] = qr(A);
```

Para calcular el error se utiliza la norma 2. El error asociado a esta descomposición es:

```
e = norm(Q*R - A)
```

```
e = 2.8383e-15
```

```
rii = diag(R);
```

Luego, calculamos su descomposición  $QR$  con los siguiente algoritmos implementados:

- Factorización QR por método de Gram-Schmidt clásico.

```
[Q1, R1] = QRbyGSC(A);
```

El error asociado es:

```
e1 = norm(Q1*R1 - A)
```

```
e1 = 1.1802e-15
```

```
rii1 = diag(R1);
```

- Factorización QR por método de Gram-Schmidt modificado.

```
[Q2, R2] = QRbyGSM(A);
```

El error asociado es:

```
e2 = norm(Q2*R2 - A)
```

```
e2 = 1.1935e-15
```

```
rii2 = diag(R2);
```

- Factorización QR por método de Householder.

```
[Q3, R3] = QRbyHouseholder(A);
```

El error asociado es:


```
e3 = norm(Q3*R3 - A)
```

```
e3 = 2.8450e-15
```

```
rii3 = diag(R3);
```

El gráfico de las componentes diagonales de la matriz triangular superior es el siguiente:

```
fig = figure();  
ax = axes(fig);  
set(ax, 'nextplot', 'add');  
o = plot(ax, abs(rii));  
o1 = plot(ax, abs(rii1));  
o2 = plot(ax, abs(rii2));  
o3 = plot(ax, abs(rii3));  
leg = legend([o, o1, o2, o3], '$|r_{ii}|$', '$|r_{ii1}|$', '$|r_{ii2}|$', '$|r_{ii3}|$');  
set(leg, 'interpreter', 'latex');
```



Donde los valores de  $r_{iiN}$ , con  $N = 0, 1, 2, 3$  representan la diagonal de la matriz R respectiva. Del gráfico se concluye que estos valores son idénticos a excepción de un signo, esto se debe a que es posible multiplicar por un  $-1$  en ambas matrices, por lo que, como también los errores relativos son pequeños, los métodos utilizados son equivalentes. Notemos que, por sobre todo esto, la matriz está bien condicionada.

### Pregunta 3.2

Ahora se utiliza una matriz de Hilbert con  $n = 20$ . Esta matriz es conocida por ser mal condicionada.

```
H = hilb(20);
cond(H)
```

```
ans = 2.1065e+18
```

```
[Q, R] = qr(H);
```

Para calcular el error se utiliza la norma 2. El error asociado a esta descomposición es:

```
e = norm(Q*R - H)
```

```
e = 3.5079e-16
```

```
rii = diag(R);
```

Luego, calculamos su descomposición  $QR$  con los siguiente algoritmos implementados:

- Factorización QR por método de Gram-Schmidt clásico.

```
[Q1, R1] = QRbyGSC(H);
```

El error asociado es:

```
e1 = norm(Q1*R1 - H)
```

```
e1 = 3.2164e-17
```

```
rii1 = diag(R1);
```

- Factorización QR por método de Gram-Schmidt modificado.

```
[Q2, R2] = QRbyGSM(H);
```

El error asociado es:

```
e2 = norm(Q2*R2 - H)
```

```
e2 = 6.6324e-17
```

```
rii2 = diag(R2);
```

- Factorización QR por método de Householder.

```
[Q3, R3] = QRbyHouseholder(A);
```

El error asociado es:

```
e3 = norm(Q3*R3 - A)
```

```
e3 = 2.8450e-15
```

```
rii3 = diag(R3);
```


El gráfico de las componentes diagonales de la matriz triangular superior es el siguiente:

```
fig = figure();  
ax = axes(fig);  
set(ax, 'nextplot', 'add');
```

```

o = plot(ax, abs(rii));
o1 = plot(ax, abs(rii1));
o2 = plot(ax, abs(rii2));
o3 = plot(ax, abs(rii3));
leg = legend([o,o1, o2, o3], '$|r_{ii}|$', '$|r_{ii1}|$', '$|r_{ii2}|$', '$|r_{ii3}|$');
set(leg, 'interpreter', 'latex');

```




Del gráfico se puede ver que los coeficientes de R obtenido por Householder difiere del resto. Se grafican los demas  $r_{ii}$

```

fig2 = figure();
ax2 = axes(fig2);
set(ax2, 'nextplot', 'add');
o = plot(ax2, abs(rii));
o1 = plot(ax2, abs(rii1));
o2 = plot(ax2, abs(rii2));
leg = legend([o,o1, o2], '$|r_{ii}|$', '$|r_{ii1}|$', '$|r_{ii2}|$');
set(leg, 'interpreter', 'latex');

```




De este gráfico, podemos notar que el método de Gram-Schmidt es más estable que el método dado por Householder. Esto es fácil de notar cuando se utiliza una matriz mal condicionada.

## Pregunta 4

Maximiliano Rivera

```
f = @(t) e.^(sin(4*t))/2006.787453080206;  
fplot(f, [0, 1])
```



```
m = 100; % Puntos  
t = linspace(0,1, m);  
b = f(t)';  
% n = 15;  
% x = linspace(0, 1, n);
```

- Método utilizando Ecuaciones Normales

Se utiliza la matriz de Vandermonde en el sistema  $Ax = b$ , el cual hay que minimizar.

Con  $x$  de la forma  $x = (a_0, a_1, \dots, a_{14})^T$ ,  $A$  es la matriz de Vandermonde.

```
A = fliplr(vander(t));  
A = A(:, 1:15);
```



```
Aprima = A'*A;
bprima = A'*b;
[R] = chol(Aprima)
```

Error using `chol`  
Matrix must be positive definite.

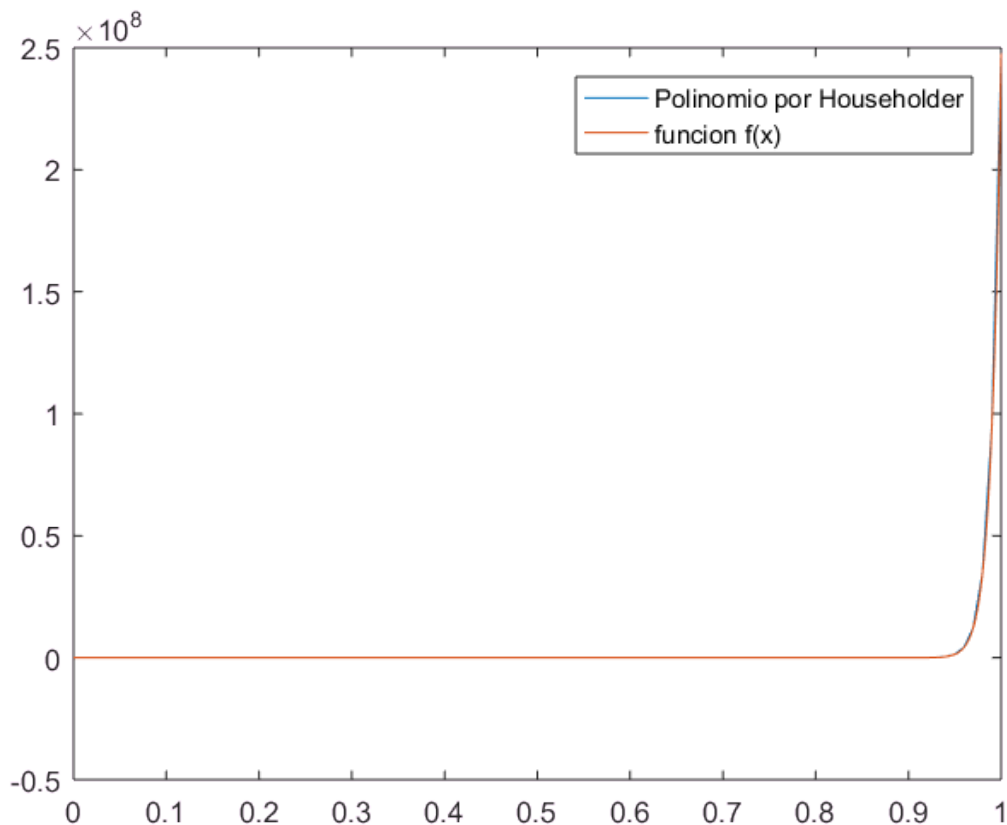
Como  $A^*A$  no es positiva definida, no presenta decomposición de Cholesky.

- Householder

```
A = vander(t);
[Q, R] = qr(A);
bprima = Q'*b;
coef = R\bprima;
```

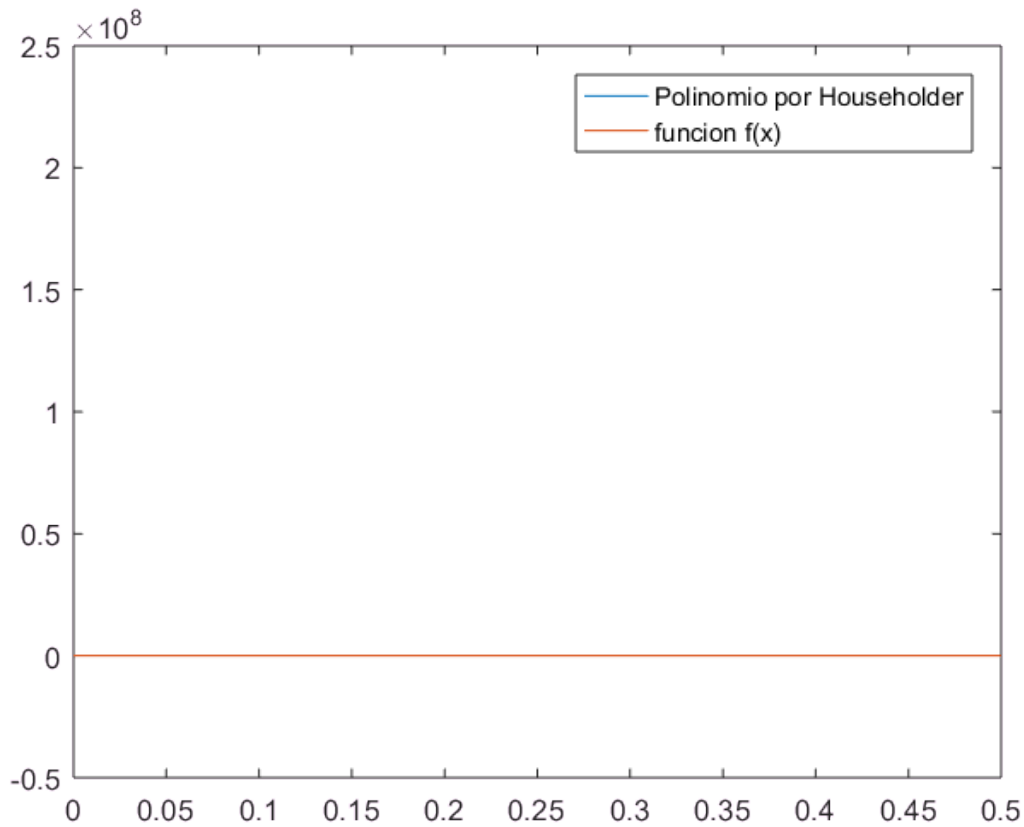
Warning: Matrix is close to singular or badly scaled. Results may be inaccurate. RCOND  
= 4.112408e-21.

```
coef_15_Householder = coef(1);
pol = polyval(coef, t);
plot(t, pol)
hold on;
fplot(f, [0, 1])
legend('Polinomio por Householder', 'funcion f(x)');
hold off;
```

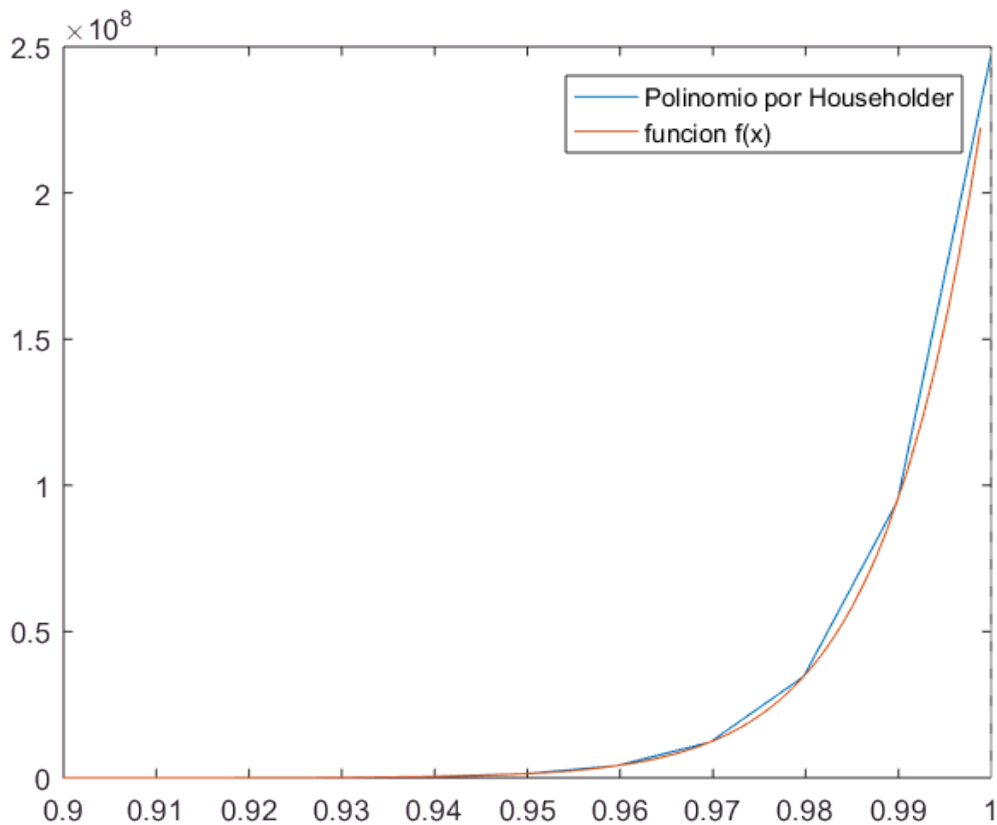


Podemos notar que el ajuste es preciso para  $x < 0.9$  aproximadamente, luego a esto, existe una diferencia considerable.

```
plot(t, pol)
hold on;
fplot(f, [0, 1])
legend('Polinomio por Householder', 'funcion f(x)');
xlim([0 0.5])
hold off;
```



```
plot(t, pol)
hold on;
fplot(f, [0, 1])
legend('Polinomio por Householder', 'funcion f(x)');
xlim([0.9 1])
hold off;
```



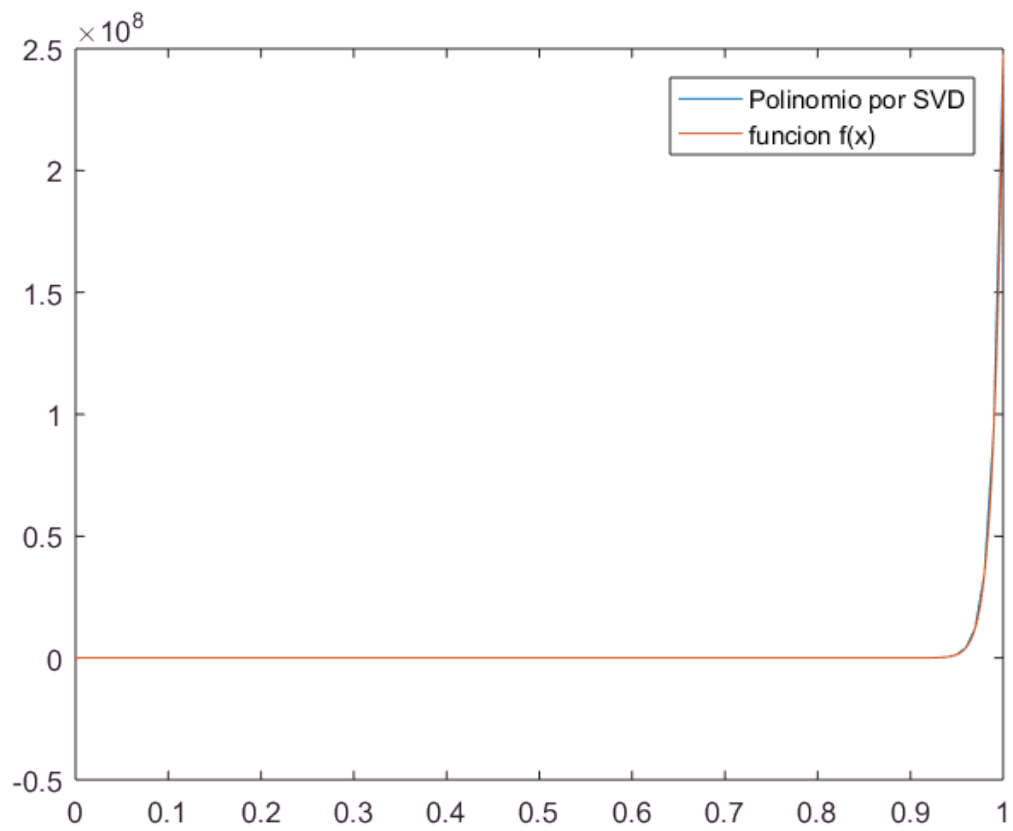
Esto se debe al gran crecimiento que presenta la función  $f(x)$ .

- SVD


```
A = vander(t);
[U,S,V] = svd(A);
bprima = U'*b;
w = S\bprima;
```

Warning: Matrix is close to singular or badly scaled. Results may be inaccurate. RCOND = 4.881463e-17.


```
coef = V*w;
coef_15_SVD = coef(1);
pol = polyval(coef, t);
plot(t, pol)
hold on;
fplot(f, [0, 1])
legend('Polinomio por SVD', 'funcion f(x)');
hold off;
```



```
plot(t, pol)
hold on;
fplot(f, [0, 1])
legend('Polinomio por SVD', 'funcion f(x)');
xlim([0 0.5])
hold off;
```



```
plot(t, pol)
hold on;
fplot(f, [0, 1])
legend('Polinomio por SVD', 'funcion f(x)');
xlim([0.9 1])
hold off;
```



El comportamiento presente al utilizar descomposición SVD es similar al por Householder.

Luego, se comparan los coeficientes 15 obtenidos.

```
coef_15_Householder
```

```
coef_15_Householder = 1.1592e+18
```

```
coef_15_SVD
```

```
coef_15_SVD = -4.8725e+12
```

Como se puede ver, los coeficientes 15 son considerablemente distintos, esto es debido a que la matriz de Vandermonde es mal condicionada, provocando inestabilidad en los métodos.